

2º Desafio em RNA/Deep Learning

A base de dados “**BaseDados_DEC.xlsx**” possui 2.540 observações referentes a características técnicas e ambientais dos conjuntos elétricos localizados na área de concessão das empresas brasileiras de distribuição de energia elétrica. Em particular, estamos interessados em modelar o comportamento médio do indicador DEC (Duração Equivalente de Interrupção por Unidade Consumidora, expresso em horas e centésimos de hora). Esta informação está localizada na coluna “**DEC_MED**” (valores médios considerando o período 2011 a 2013).

Como variáveis explicativas (ou preditoras) devem ser consideradas **SOMENTE** as informações disponíveis nas colunas ‘C’ (AREA) até a coluna ‘EE’ (ENE_PNI), totalizando 133 potenciais variáveis preditoras.

Para este problema deve ser avaliados os seguintes modelos:

- 1) Modelo de regressão linear: **lm(y ~ x)**
- 2) Modelo de Random Forest: **randomForest(y ~ x)**
- 3) Modelo de Redes Neurais Artificiais: pacote **keras**

Como medida de qualidade do ajuste, pode ser utilizada a raiz quadrada da média dos quadrados dos erros (ou resíduos):

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

(1)

indicada no comando:

```
sqrt( sum( (dados$y - predict(modelo))^2 )/nrow(dados) )
```

Em particular, estamos interessados em avaliar a **capacidade preditiva** de cada um dos modelos. Consequentemente, podemos utilizar a raiz quadrada da média dos quadrados dos erros preditivos, S_{pred} , utilizando um procedimento de validação cruzada

Procure organizar este exercício em um arquivo word, comparando os resultados e o desempenho resultante da aplicação de cada modelo. Comparando não somente as estatísticas preditivas mas também os gráficos de dispersão dos valores observados e dos valores previstos.

- 1) **Exporte o arquivo word como pdf** e submeta no minha.ufmg.br no prazo estabelecido. (O arquivo deve conter, no **máximo 5 páginas**)